上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

2026年春季学期

编译原理
Principles of Compilers

第三章：词法分析（3）

赵杰茹

上海交通大学计算机学院

内容纲要

- 词法分析器的作用
- 词法单元的规约
- 词法单元的识别
- 词法分析器生成工具LEX
- 有穷自动机(Finite Automata)
- **正则表达式到有穷自动机**
- 词法分析器生成工具的设计

从正则表达式到有穷自动机的转换

- 正则表达式
  - 简洁、易于人为书写
- 有穷自动机
  - 模拟DFA的执行可以高效地进行模式匹配
  - 状态较多时，DFA不适合手动书写
- 如何将正则表达式转换为DFA?

从正则表达式到NFA的转换

- 目标：
  - 对于字母表 Σ 上的正则表达式 r，构造能接受语言L(r)的NFA
- 步骤：

  1）如果正则表达式 r不包含运算，则 r可以是ε或者Σ上的符号a

对于表达式ε，定义其NFA：

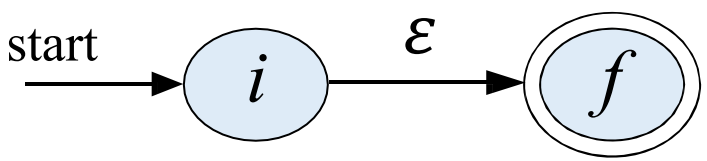

对于表达式a，定义其NFA：

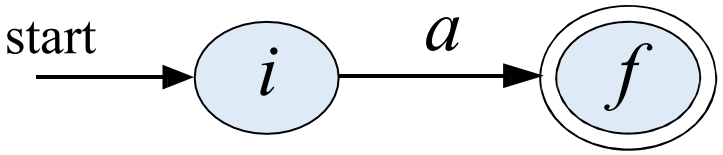

从正则表达式到NFA的转换

- 步骤：

  2）如果正则表达式r包含运算，假设正则表达式s和t的NFA分别为N(s)和N(t)

  对于表达式r=s|t，则r的NFA为：

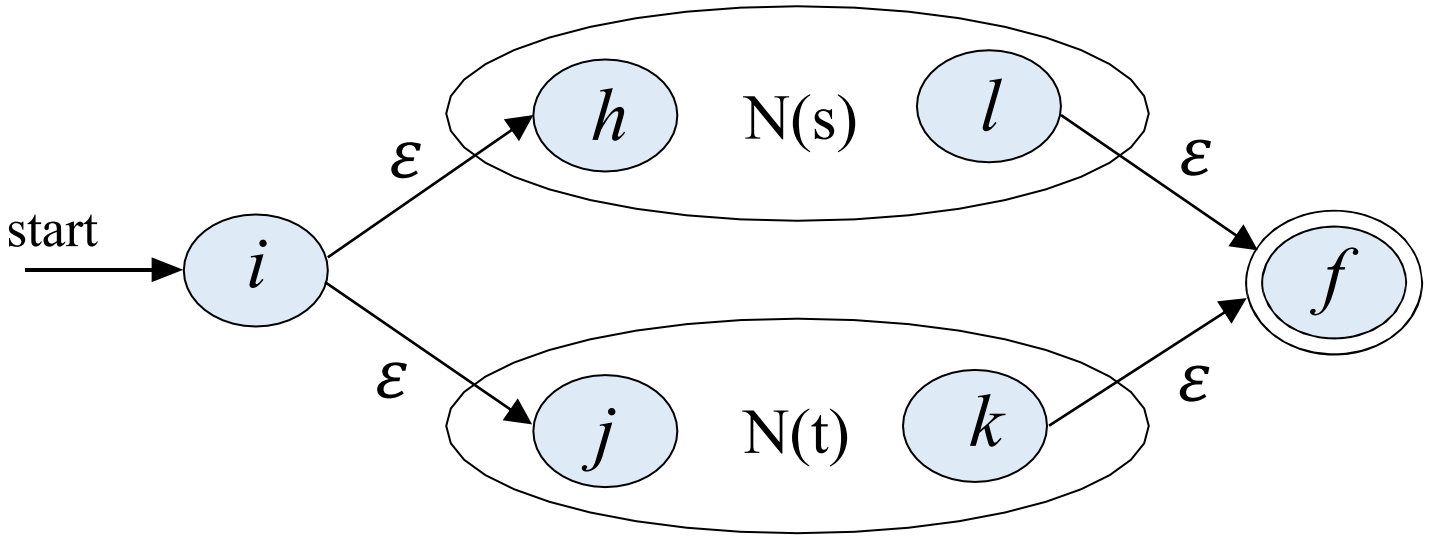

从正则表达式到NFA的转换

- 步骤：

  2）如果正则表达式r包含运算，假设正则表达式s和t的NFA分别为N(s)和N(t)

  对于表达式r=st，则r的NFA为：

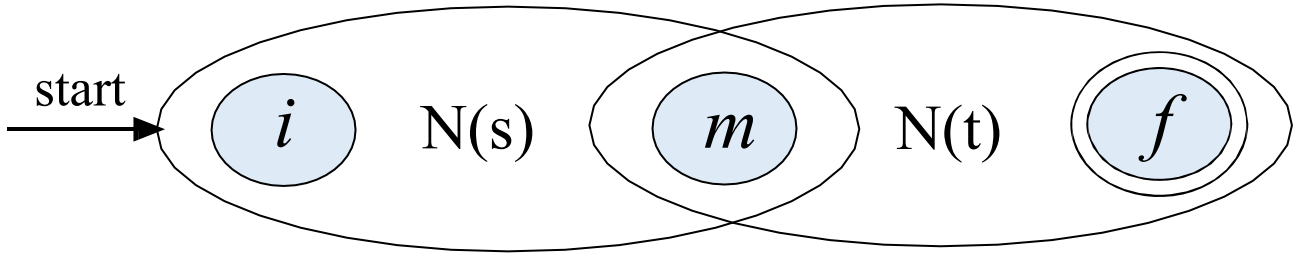

从正则表达式到NFA的转换

- 步骤：

  2）如果正则表达式r包含运算，假设正则表达式s和t的NFA分别为N(s)和N(t)

  对于表达式r=s*，则r的NFA为：

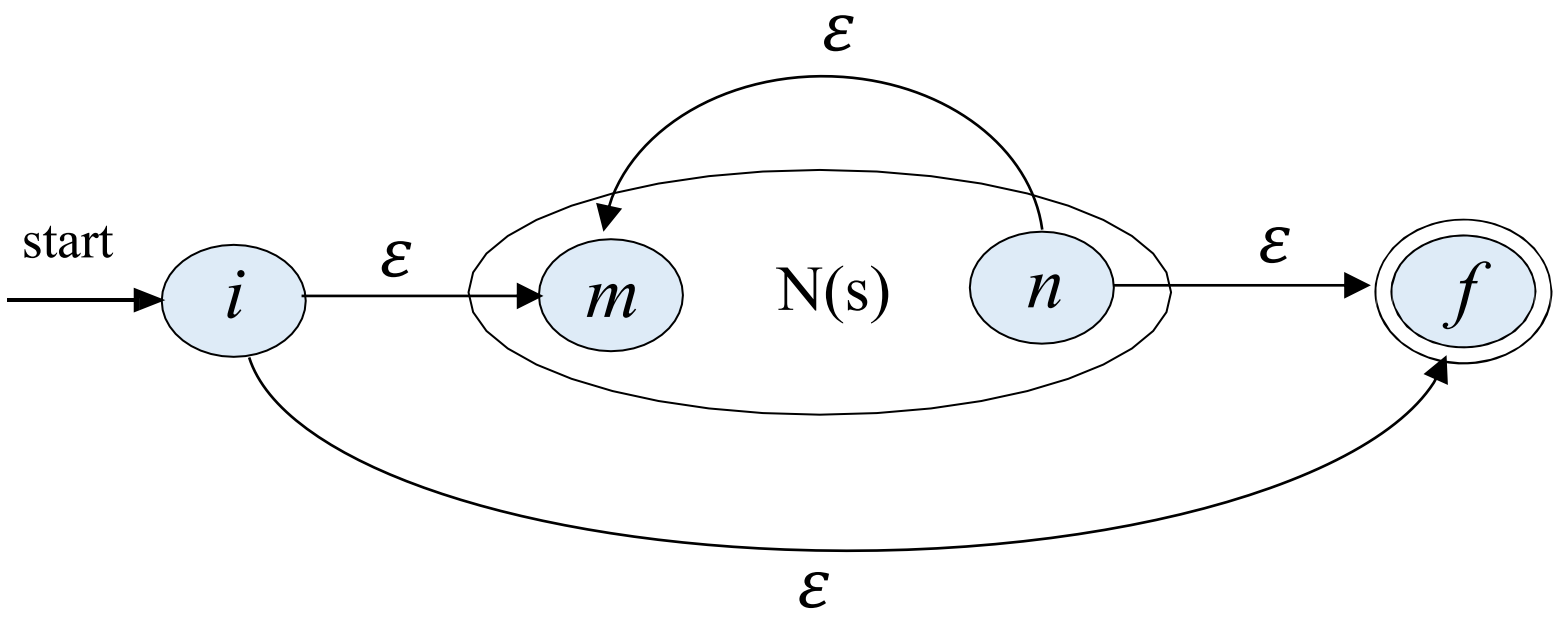

正则表达式到NFA示例-1

- 对于正则表达式 **r = 01*|1**，构造等价的NFA

0

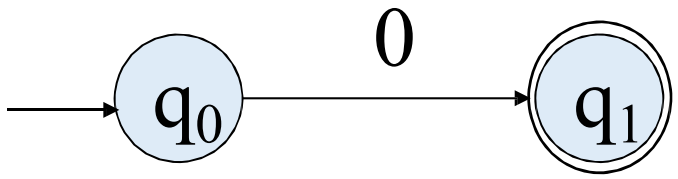

1

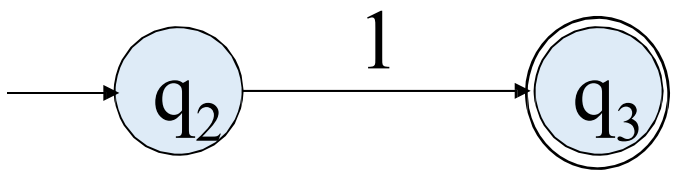

1*

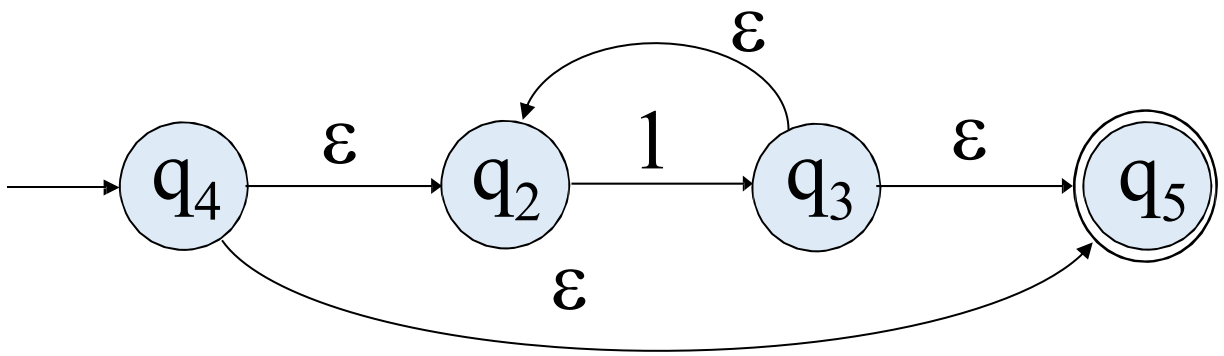

正则表达式到NFA示例-1

01*

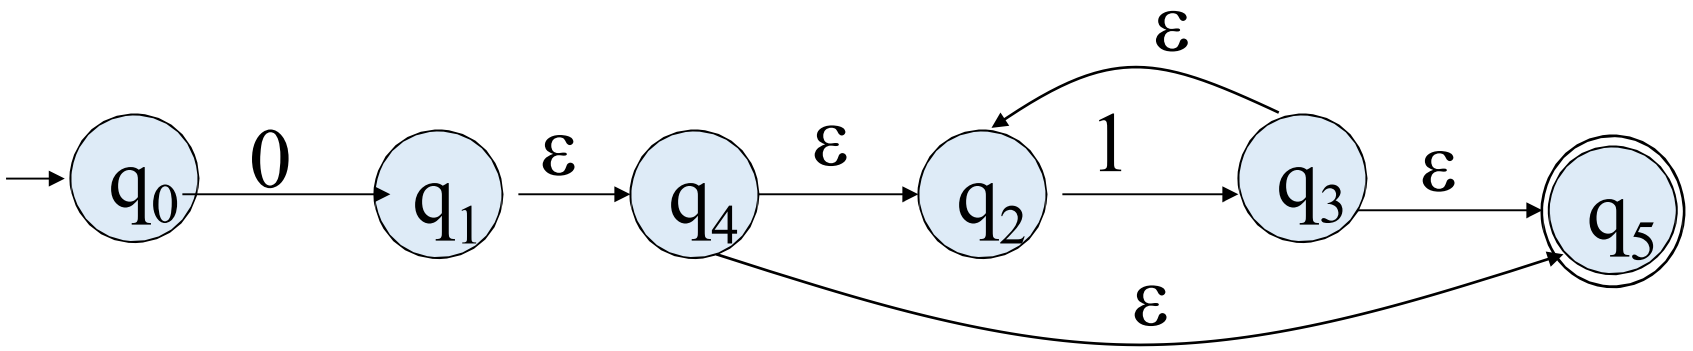

1

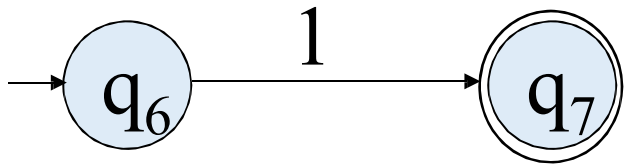

01*| 1

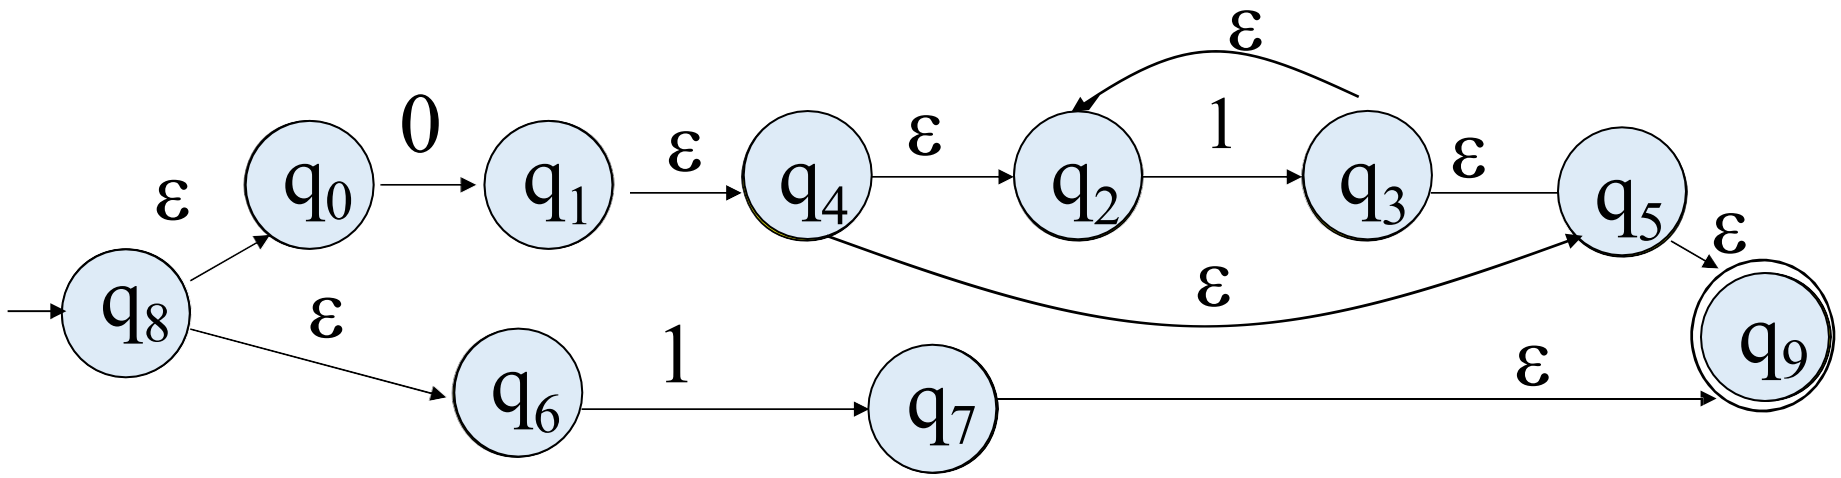

正则表达式到NFA示例-2

- 对于正则表达式 **r = (a|b)*abb**，构造等价的NFA

a

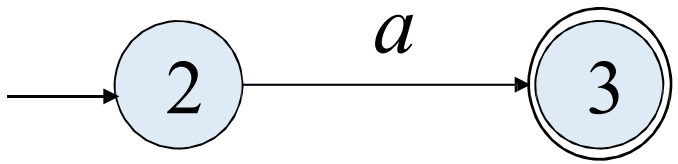

b

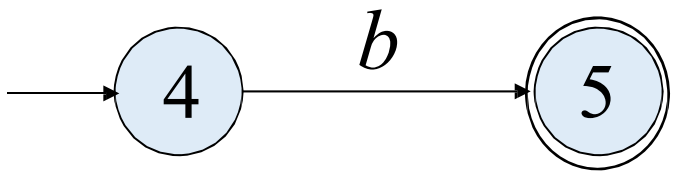

a|b

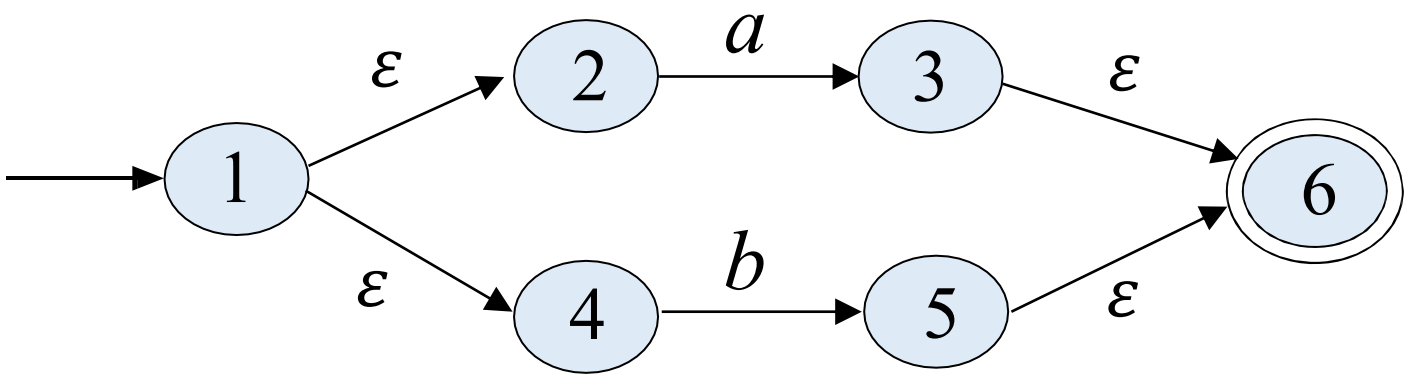

正则表达式到NFA示例-2

- 对于正则表达式 **r = (a|b)*abb**，构造等价的NFA

(a|b)*

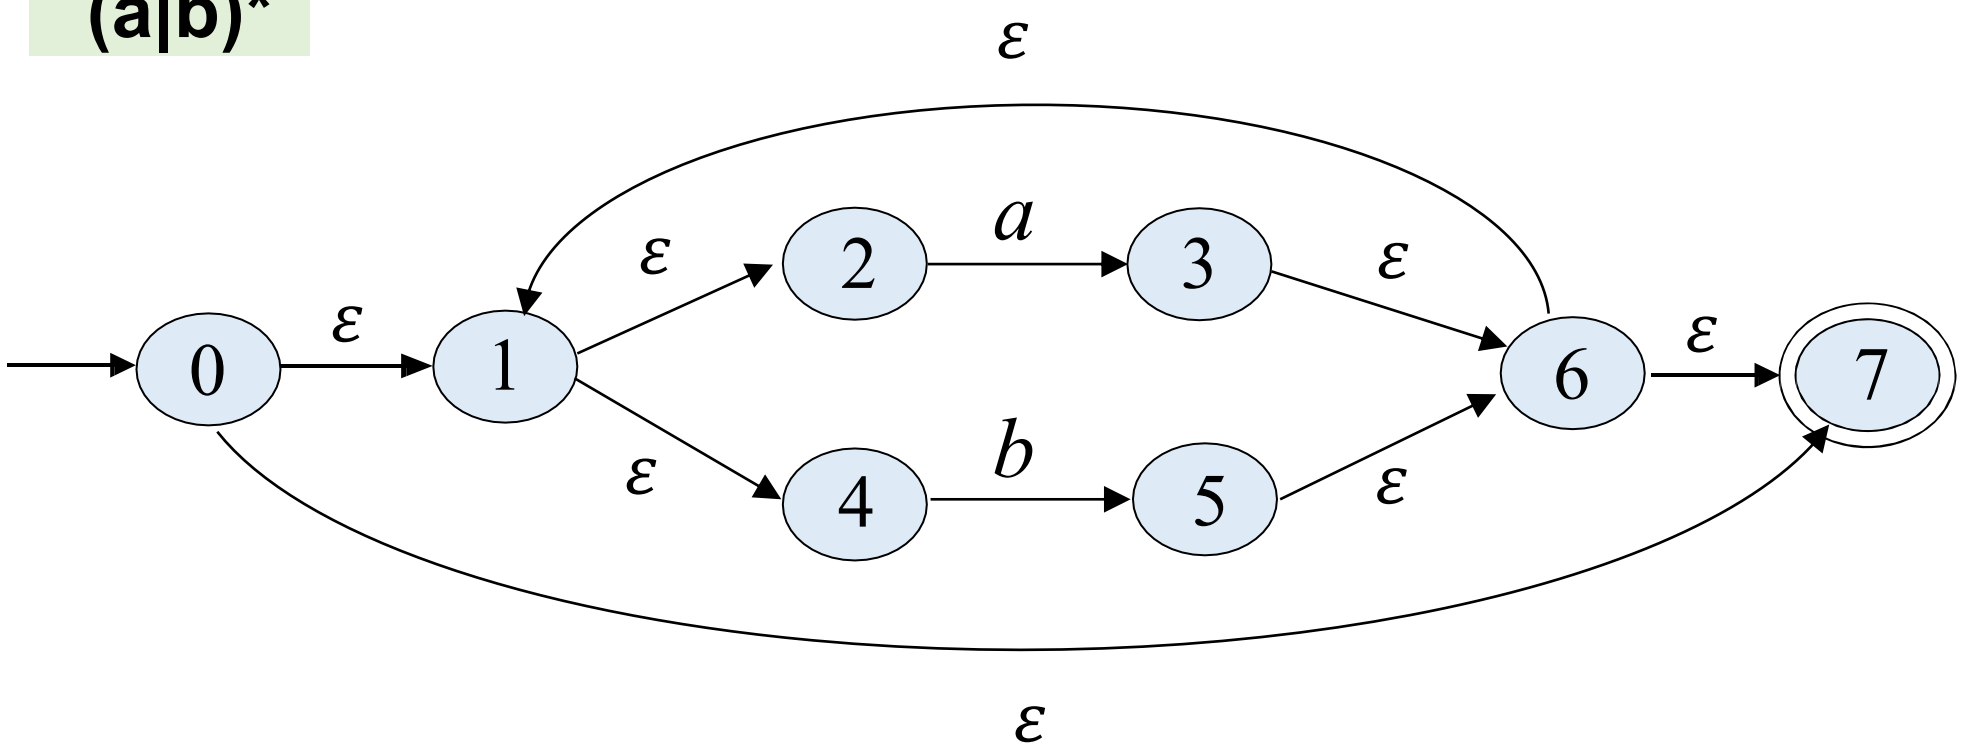

正则表达式到NFA示例-2

- 对于正则表达式 **r = (a|b)*abb**，构造等价的NFA

(a|b)*abb

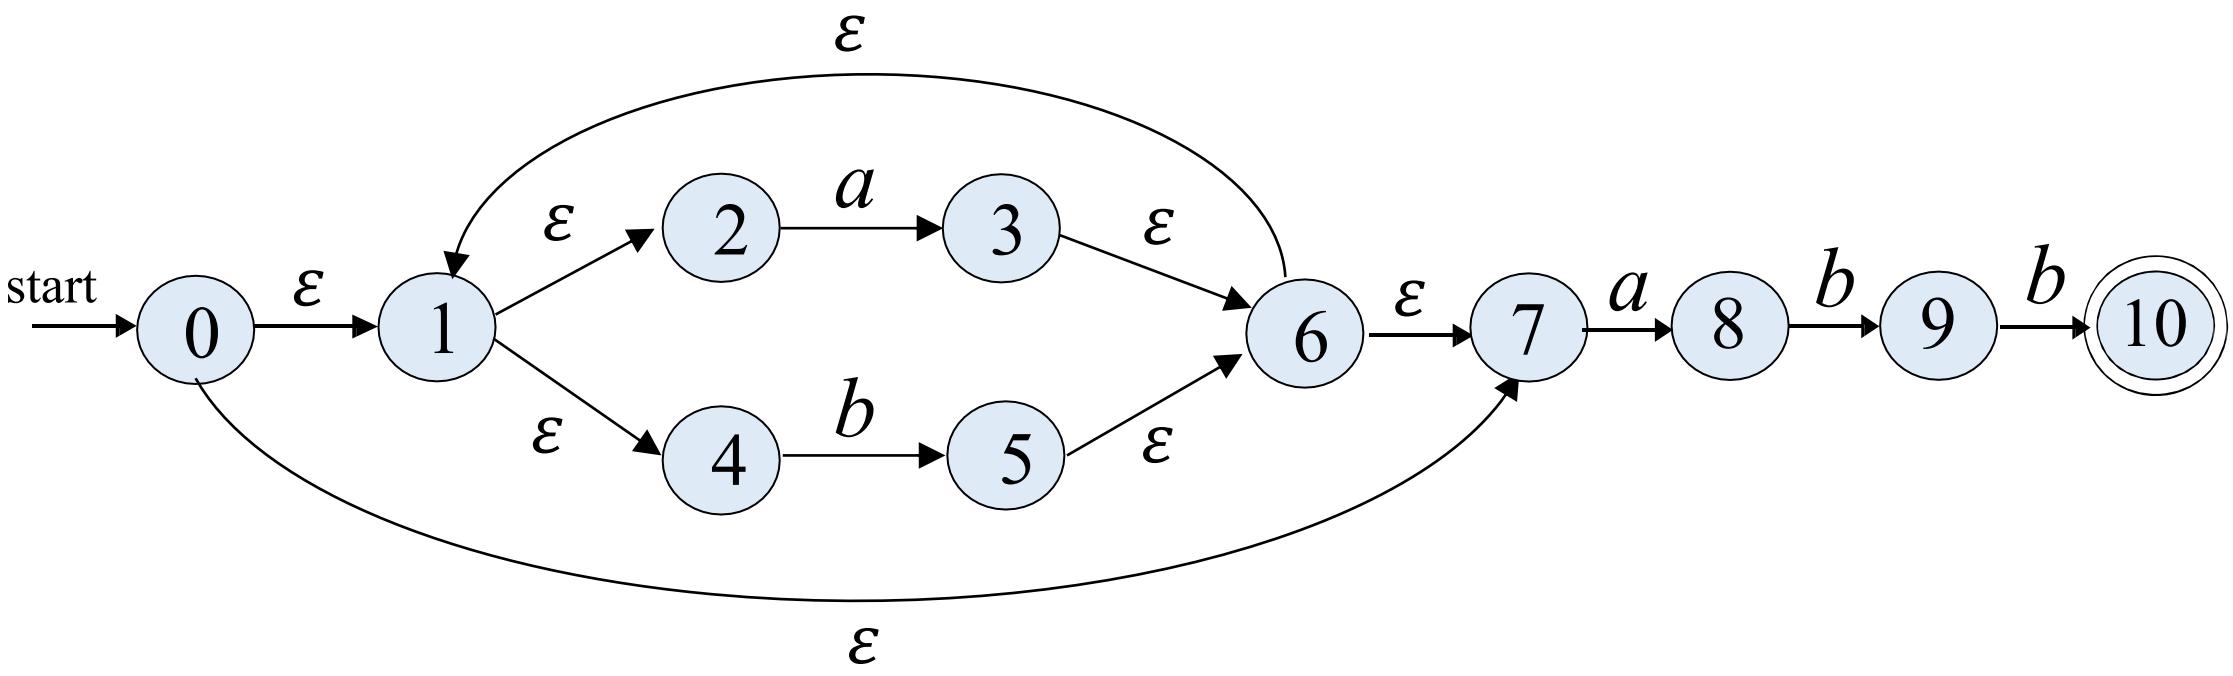

从NFA到DFA的转换

- NFA和DFA的等价性：
  - 对于任何一个NFA，存在等价的DFA来表示同一种语言

- 子集构造法（subset construction）
  - 基本思想：使构造的DFA的每个状态，对应于NFA的一个状态集合
    - 也就是说，DFA在读入输入$a_1 \dots a_n$后到达的状态，对应于相应的NFA从开始状态出发，沿着以$a_1 \dots a_n$为标号的边，到达的状态集合

NFA到DFA示例

- 正则表达式 **r = (a|b)*abb** 的NFA：

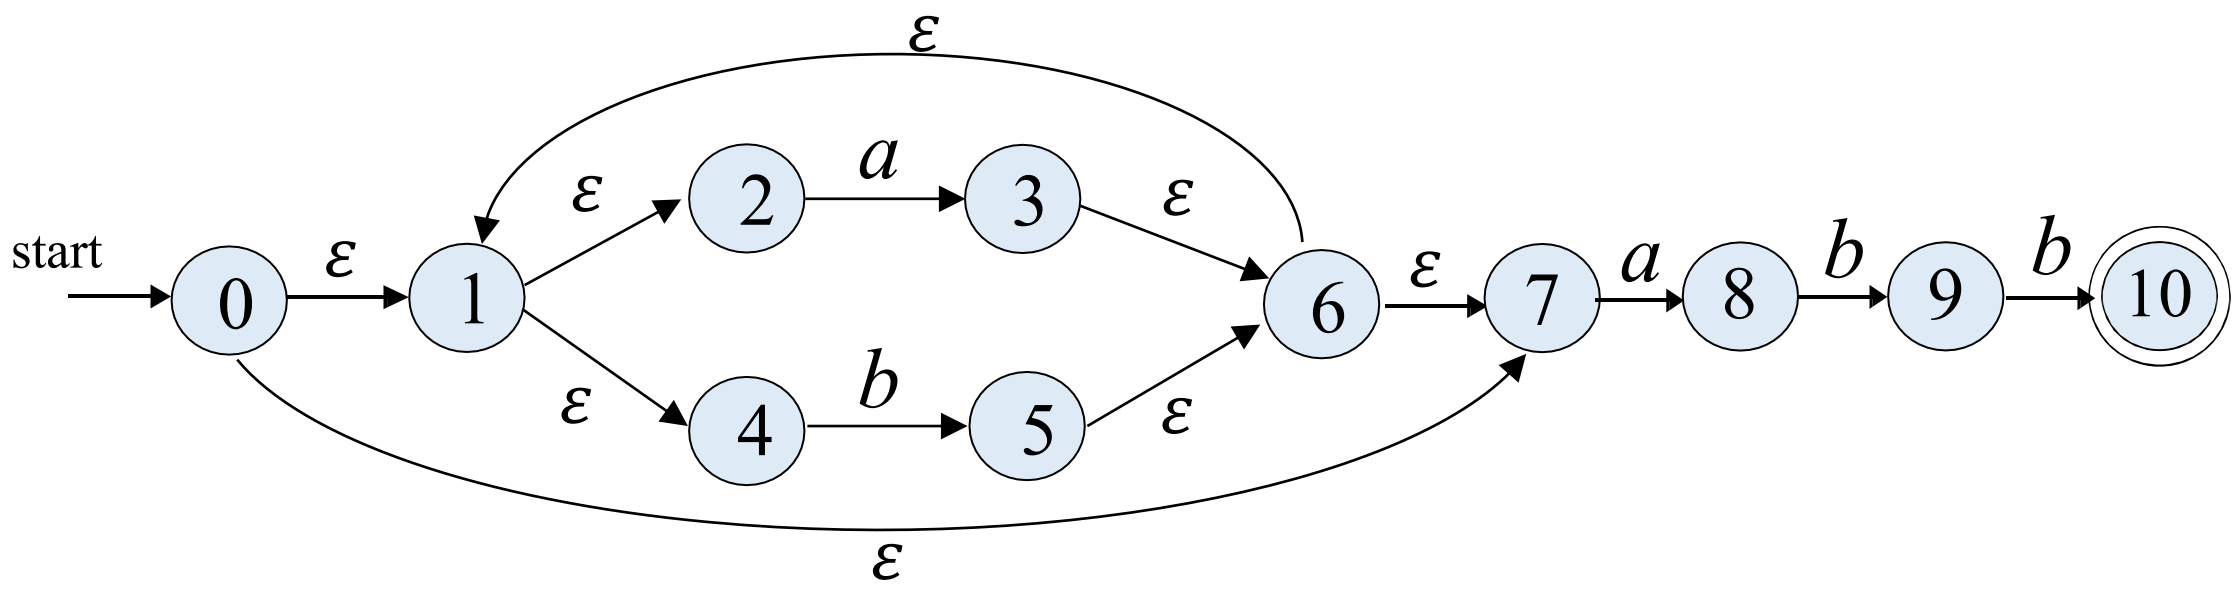

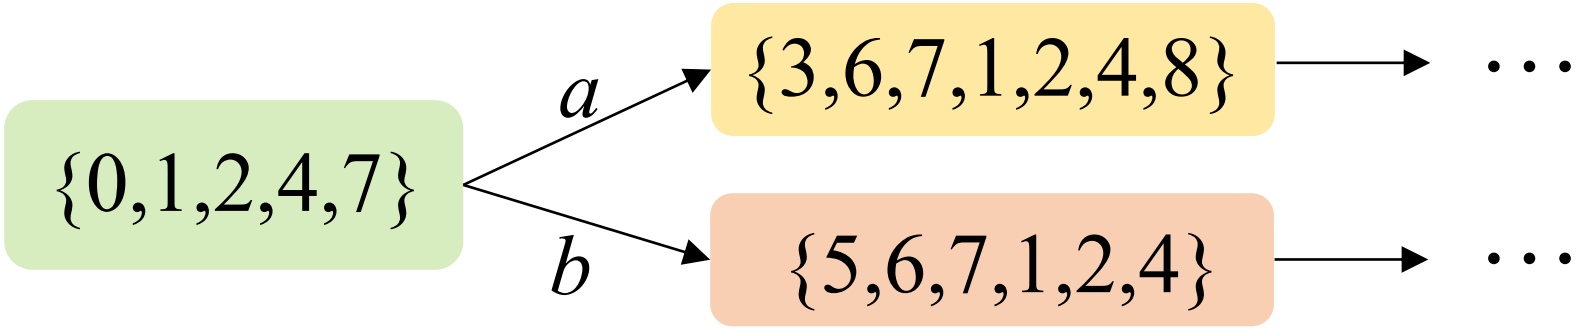

子集构造法

- 基本函数定义
  - **ε_closure(s)**：从NFA的状态s开始只通过ε转换到达的NFA状态集合
  - **ε_closure(T)**：从T中某个NFA状态s开始只通过ε转换到达的NFA状态集合，即 $\bigcup_{s\epsilon T}$ ε_closure(s)
  - **move(T, a)**：从T中某个状态s出发通过标号为a的转换到达的NFA状态集合
- 从NFA到DFA：
  - **开始状态**：令s_0为NFA的开始状态，则相应DFA的开始状态为ε_closure(s_0)
  - **接受状态**：DFA接受状态是所有至少包含NFA的一个接受状态的状态集合
  - **转换**：我们将NFA的状态集合S到状态集合S'的转换添加到相应的DFA中，当且仅当 S'= ε_closure(move(S, a))

NFA到DFA示例

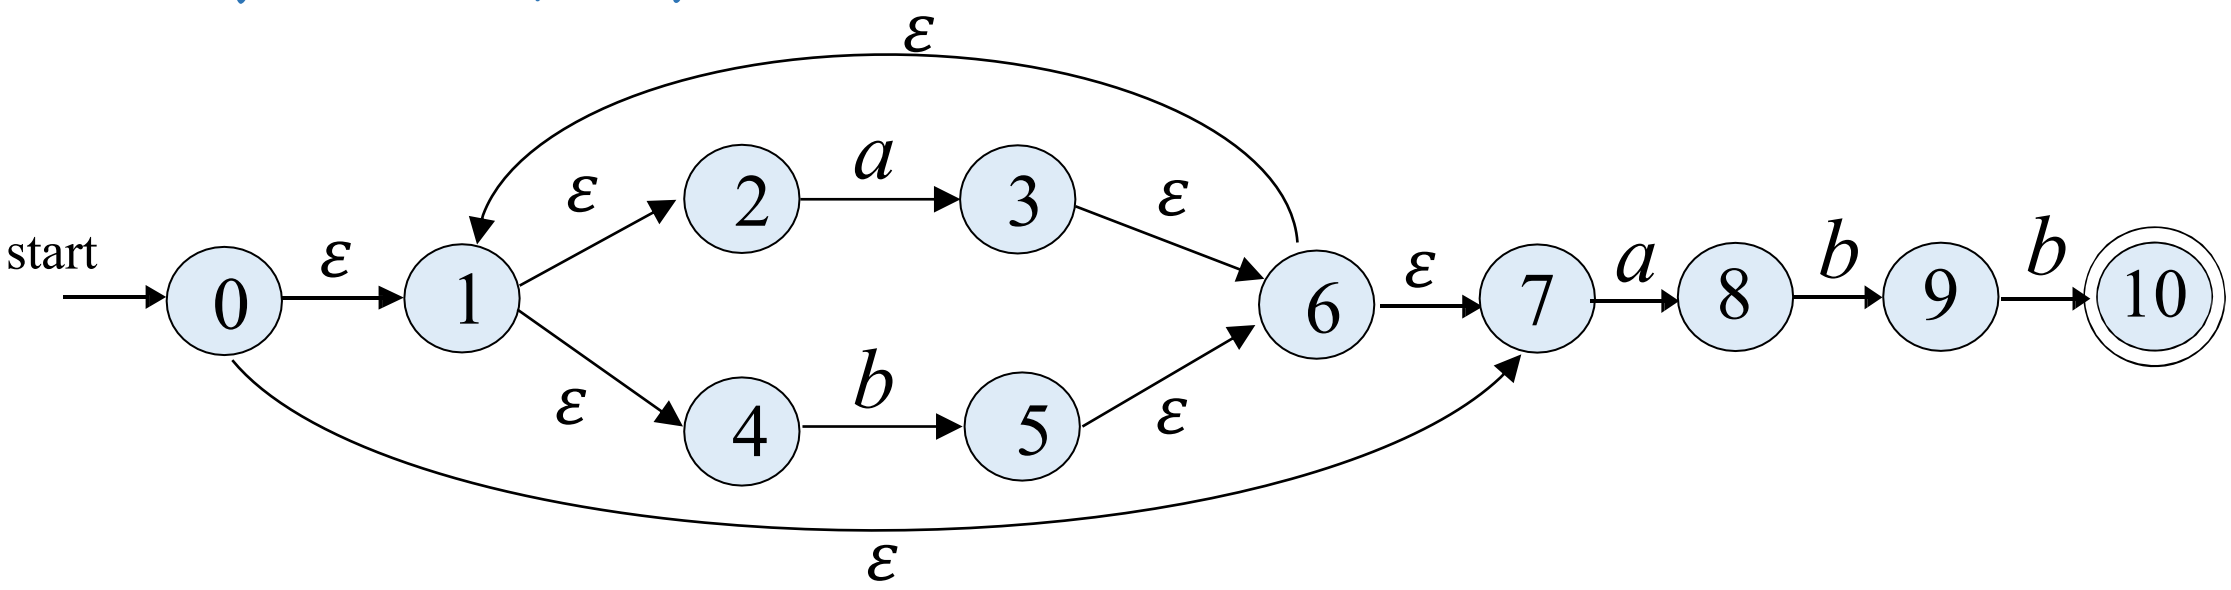

NFA状态	DFA状态	*a*	*b*
{0,1,2,4,7}	A	B	C
{1,2,3,4,6,7,8}	B	B	D
{1,2,4,5,6,7}	C	B	C
{1,2,4,5,6,7,9}	D	B	E
{1,2,4,5,6,7,10}	E	B	C

转换后得到的DFA

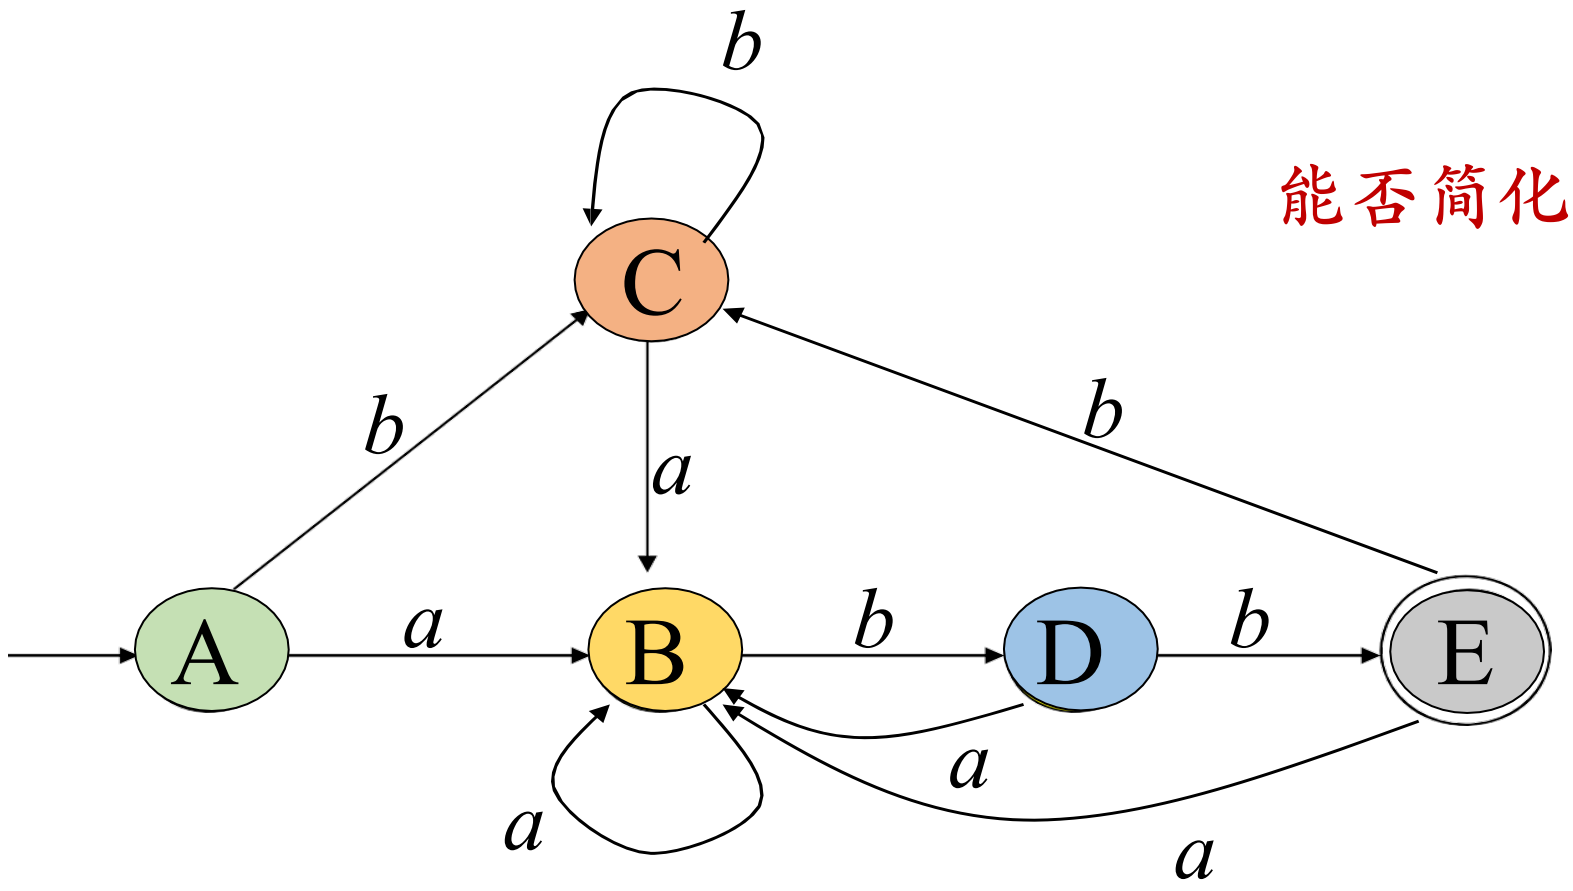

能否简化这个DFA?

合并等价状态

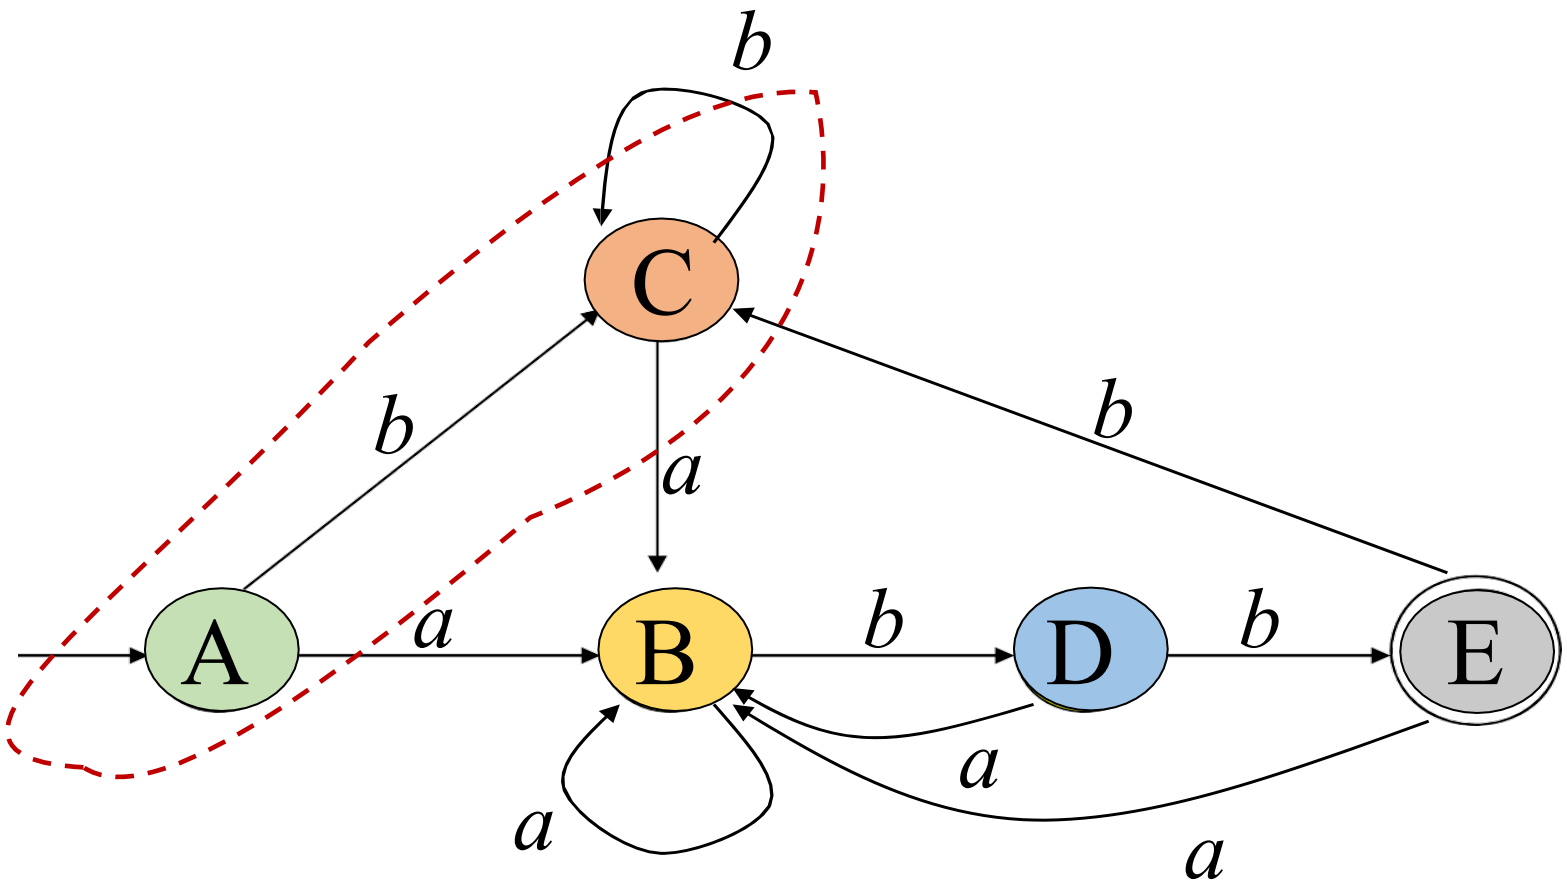

DFA的最小化

- 任何正则语言都有一个唯一的状态数目最少的DFA
- 区分与等价
  - 如果分别从状态s和t出发，沿着标号x的路径到达的状态中只有一个是接受状态，则串x**区分**状态s和t
  - 存在这样的串，则两个状态s和t是**可区分的**，否则两状态等价
- 如何最小化DFA状态数?
  - 将DFA的状态集合**划分**成多组，每个组中的状态之间相互不可区分（等价）

DFA的最小化

状态最小化算法

1. 首先把所有状态划分为两个组：接受状态组和非接受状态组
2. 任意选定一个输入符号a，判断每个组中的各个状态对于a的转换，如果落入不同的组中，就把该组中的状态按照转换之后的组进行分割，使分割后的每个组对于a的转换都会落入同一个组。
3. 重复第2步，直至每个组中的所有状态都等价。

DFA最小化示例

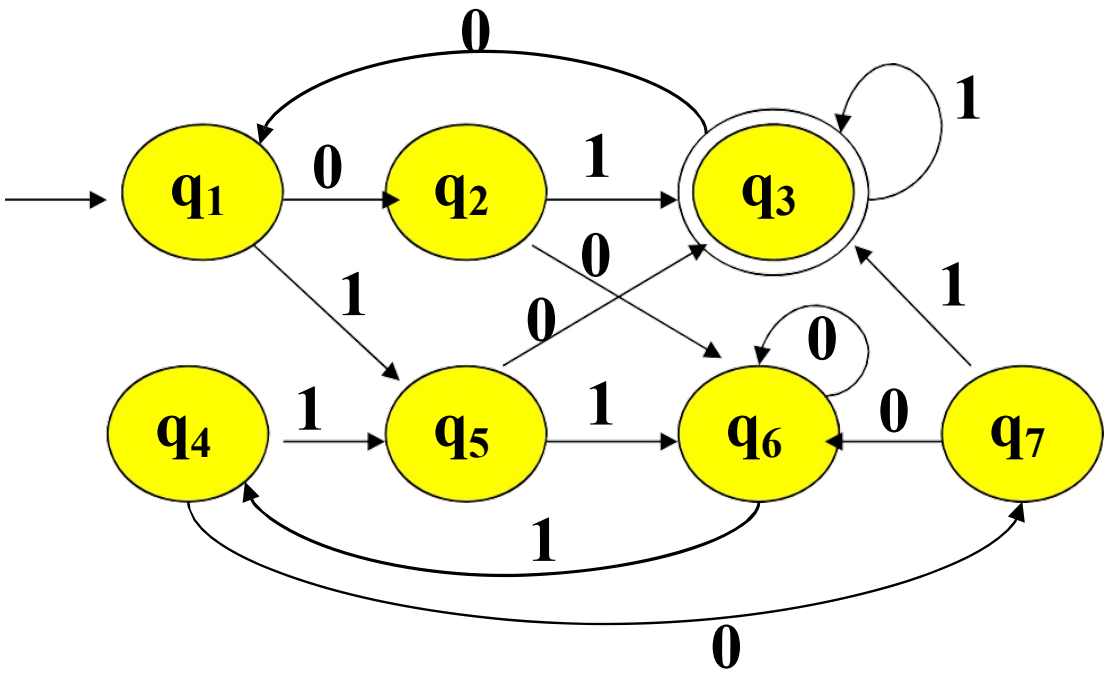
q1
q2
q3
q4
q5
q6
q7
0
1

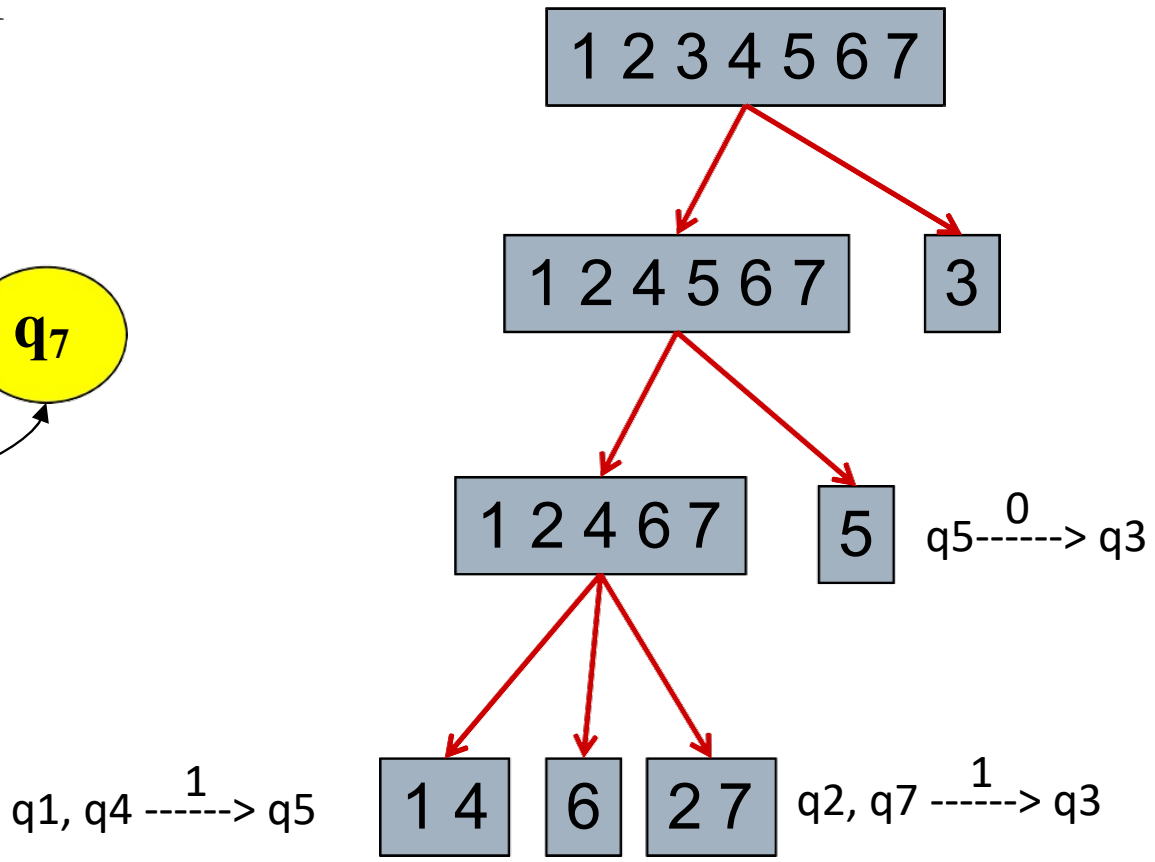
1 2 3 4 5 6 7
1 2 4 5 6 7
3
1 2 4 6 7
5
q5 --0--> q3
1 4
6
2 7
q1, q4 --1--> q5
q2, q7 --1--> q3

DFA最小化示例

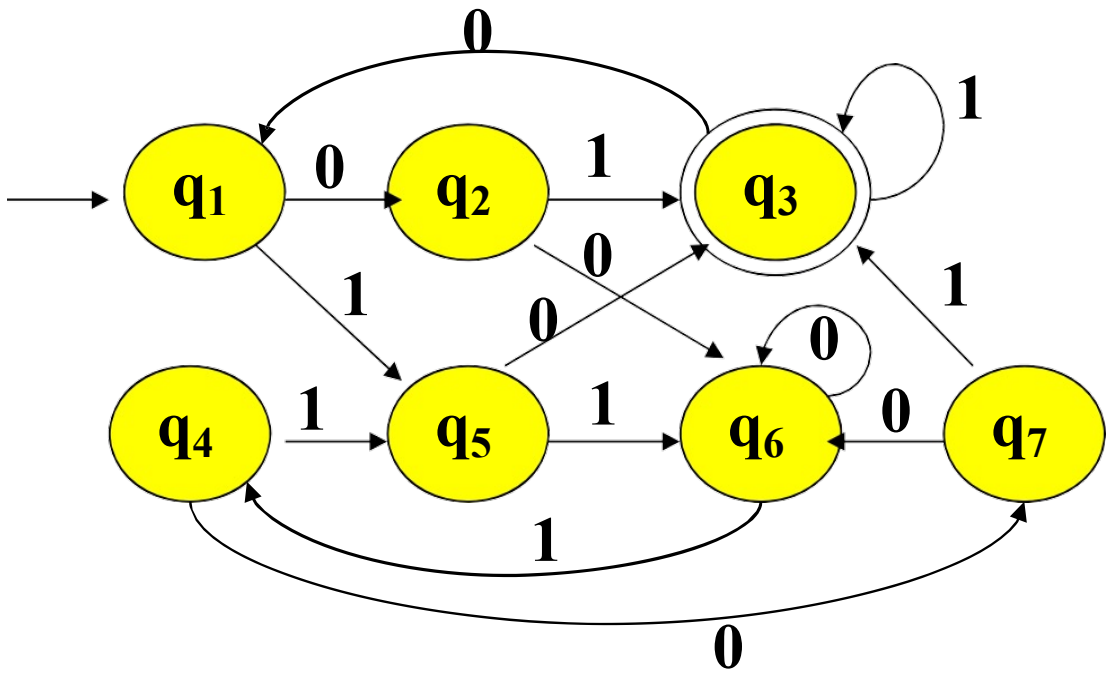

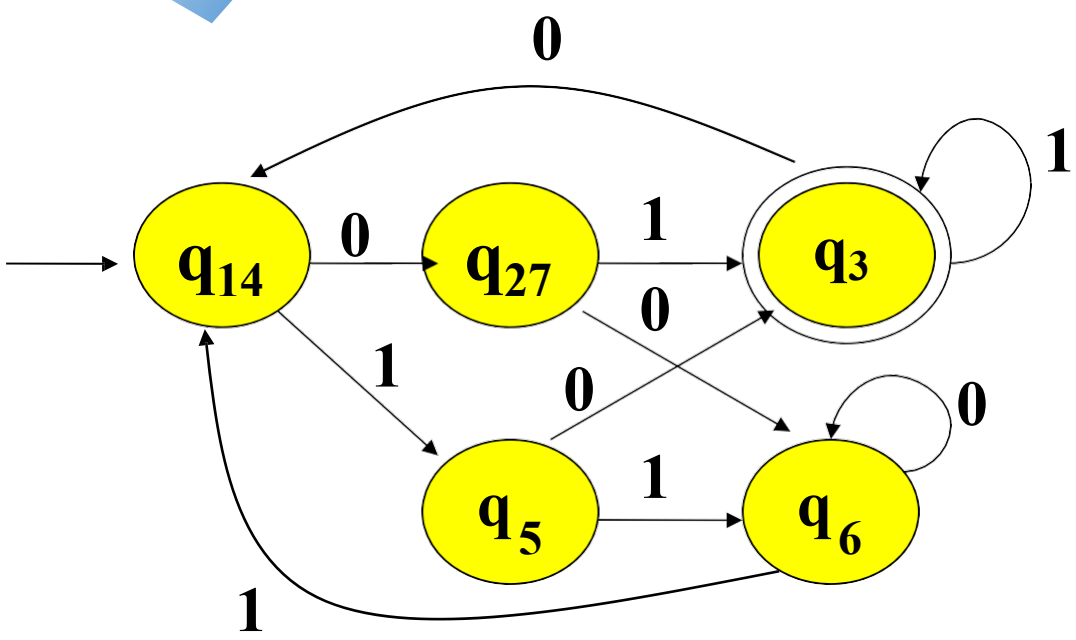

内容纲要

- 词法分析器的作用
- 词法单元的规约
- 词法单元的识别
- 词法分析器生成工具LEX
- 有穷自动机(Finite Automata)
- 正则表达式到有穷自动机
- 词法分析器生成工具的设计

词法分析器生成工具的结构

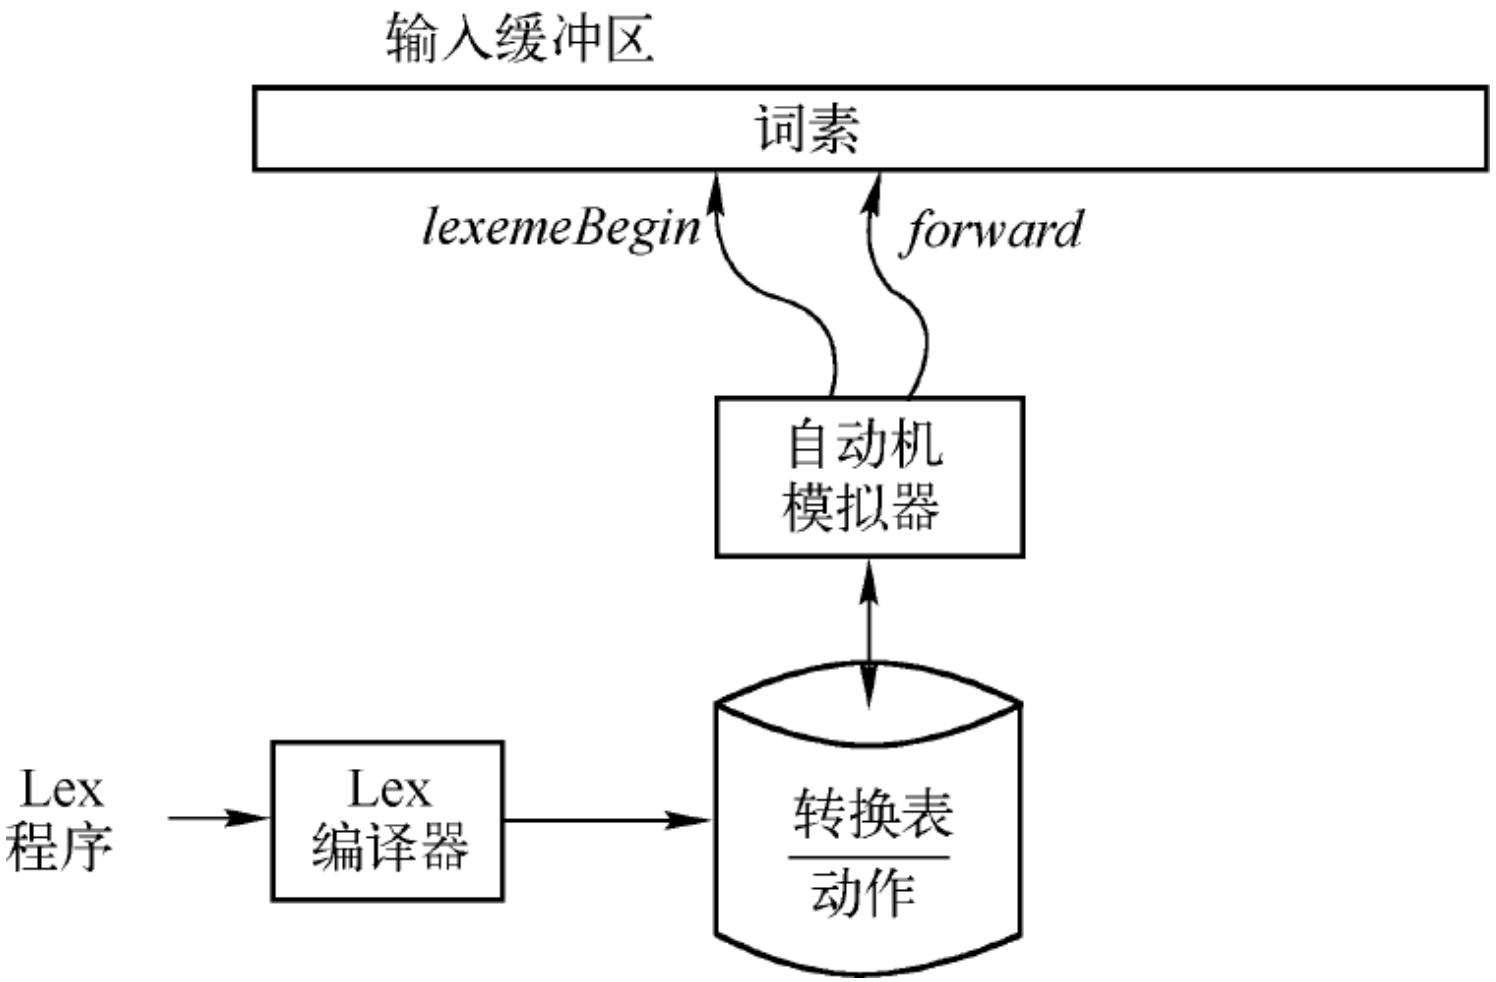

词法分析器生成工具的结构

- 生成的词法分析器中包含一个模拟有穷自动机的模块
- 其余部分由生成工具根据词法规则的描述自动生成，包括
  - 自动机的转换表
  - 和动作相关的代码，适当的时候由模拟器调用
- 构造有穷自动机模块时
  - 首先构造出各个模式对应的NFA
  - 然后将这些NFA合并成为一个NFA
  - （根据需要）进行确定化，转换成DFA

详细内容阅读3.8和3.9章节

本章总结

- 描述：词法规则通常可以使用**正则表达式**来描述
  - 词法单元、模式、词素
  - 正则表达式、正则定义、正则语言
  - 多种运算
- 识别：构建**有穷自动机**用于匹配词法单元的模式
  - NFA、DFA
  - 正则表达式到有穷自动机的转换
  - DFA的最小化
- 词法分析器生成工具Lex
  - 工作原理